

Krisha Agent.

AI-агент для анализа квартир на Krisha.kz —
справедлива ли цена?

АВТОР	ТЕХНОЛОГИЯ	ДАННЫЕ	ТОЧНОСТЬ
Амирлан	LangGraph + GPT-4o	37 763 объявл.	86.7%

Покупатель не знает — переплачивает он или нет.

- 01 **Ручной анализ** 20–30 объявлений занимает несколько часов — результат субъективный.
- 02 **Риелтор заинтересован в продаже** — его совету покупатели не доверяют.
- 03 **Реальное состояние ремонта** по фото без эксперта оценить почти невозможно.
- 04 Нет быстрого способа сравнить квартиру **с похожими предложениями рынка**.

ЦЕЛЕВОЙ ПОЛЬЗОВАТЕЛЬ

Человек 25–40 лет, покупает первую квартиру в Алматы. Не имеет экспертизы в оценке недвижимости. Доверяет данным, а не мнениям.

"Вставил ссылку — получил вердикт за 20 секунд."

В БАЗЕ	АНАЛИЗ ФОТО	РАЙОНОВ АЛМАТЫ	СТОИМОСТЬ ЗАПРОСА
37 763	10	8	\$0.12
реальных объявлений	GPT-4o Vision	в базе данных	один анализ

ШАГ 01	ШАГ 02	ШАГ 03
Ссылка на объявление	Агент анализирует	Вердикт с цифрами
krisha.kz/a/show/... — агент сам парсит страницу	Данные объявления · Рынок района · Все фото	Выгодно · Рыночная цена · Дорого

Анализ реального объявления.

Вход krisha.kz/a/show/1010382901 # fetch_listing → 2-комн · 65м² · 7/14 эт Бостандыкский · 50 000 000₸ # analyze_photos → score: 7/10 · ремонт: не нужен корректировка: +3% # evaluate_price → рынок: 750 000₸/м² монолит 2017: +2% · итого: +5% справедливо: 47.5–55.8 млн

 **РЫНОЧНАЯ ЦЕНА** — цена соответствует рынку

ПАРАМЕТР	ЗНАЧЕНИЕ
Цена продавца	769 230₸/м²
Средний рынок	750 000₸/м²
Справедливая цена	47.5–55.8 млн

РЕКОМЕНДАЦИЯ АГЕНТА

Цена в рыночном диапазоне. Торгуйтесь на 5–7% — монолит 2017 уже не новостройка, ремонт хороший, но не свежий.

LangGraph граф — ветвление и human-in-the-loop.



↳ ошибка загрузки → сразу END ↳ пользователь задаёт вопрос → human_review отвечает в контексте

ВЕТВЛЕНИЕ

После fetch_listing

404 или блокировка → граф уходит в END с сообщением. Пользователь не видит пустой экран.

HUMAN-IN-THE-LOOP

human_review

Ждёт follow-up вопрос. GPT-4o-mini отвечает в контексте без повторного запуска пайплайна.

ПОЧЕМУ LANGGRAPH

А не LCEL / CrewAI

LCEL — нет human-in-the-loop. CrewAI — избыточен для одного агента. LangGraph — нужный минимум.

Каждый выбор — обоснован.

КОМПОНЕНТ	ВЫБОР	ПОЧЕМУ ИМЕННО ЭТО	АЛЬТЕРНАТИВА — ПОЧЕМУ ОТКАЗАЛИСЬ
Оркестрация	LangGraph	Ветвления + human-in-the-loop из коробки	CrewAI — избыточен для одного агента
Vision анализ	GPT-4o	Лучшее качество для анализа фото ремонта	Gemini — хуже на русских подписях
Рекомендации	GPT-4o-mini	A/B тест: качество = gpt-4o, цена в 10× меньше	gpt-4o — избыточен, доказано тестом
Эмбеддинги	text-embedding-3-small	\$0.02/1M токенов, достаточно для коротких текстов	large — в 5× дороже без прироста качества
Vector DB	ChromaDB	Локальная, 36k документов в памяти, поиск 20мс	Qdrant — нужен отдельный сервер
База данных	SQLite	37k строк — overhead не нужен, IQR фильтр	PostgreSQL — избыточен для read-only
MCP сервер	FastMCP	Минимум кода, автосхема для LLM	REST API — нет JSON-схемы для модели
Мониторинг	LangSmith	Трейсы каждой ноды, токены, latency	—

Как считается справедливая цена.

```
# Шаг 1: рыночная база avg_m2 = SQLite(district, rooms, area  $\pm 30\%$ ,  
IQR фильтр) # Шаг 2: корректировки год: до 1950  $\rightarrow -35\%$  2020+  $\rightarrow +8\%$   
этаж: 1-й  $\rightarrow -5\%$  последний  $\rightarrow -3\%$  тип: панель  $\rightarrow -10\%$  монолит  $\rightarrow +5\%$   
фото: 1-2  $\rightarrow -15\%$  9-10  $\rightarrow +10\%$  # Шаг 3: диапазон  $\pm 8\%$  fair = avg_m2  $\times$   
(1 + adj%)  $\times$  area range = [fair  $\times 0.92$ , fair  $\times 1.08$ ]
```

ПОЧЕМУ АЛГОРИТМ, А НЕ LLM

Детерминированный код = предсказуемость. Каждый коэффициент задокументирован. LLM мог бы галлюцинировать числа.

ПОЧЕМУ $\pm 30\%$ ПО ПЛОЩАДИ

60м² сравнивается только с 42–78м², не со всеми 2-комнатными. Без фильтра медиана искажается крайними значениями.

ПОЧЕМУ IQR

Убирает нотариальные (1Т) и ошибки парсинга. Медиана устойчива к выбросам — нотариальные сделки не искажают рынок.

GPT-4o Vision — не для галочки.

SCORE	ЗНАЧЕНИЕ	КОРРЕКТИРОВКА
9–10	Евроремонт / новостройка	+10%
7–8	Свежий ремонт	+3%
5–6	Жилое, косметика нужна	0%
3–4	Требует полного ремонта	−8%
1–2	Аварийное состояние	−15%
· Все 10 фото из объявления в одном запросе к GPT-4o		
· Жёсткие якоря в промпте — модель не ставит 7–8 "по умолчанию"		
· Флаг low_confidence для тёмных/размытых фото — не штрафует		
· Корректировка % — детерминированная функция, не модель		

БЕЗ VISION

Продавец пишет "хороший ремонт". Агент верит → вердикт **"выгодно"**.

С VISION

Агент видит советские батареи и штукатурку → score=3 → −8% → вердикт **"дорого"**.

ПРОМПТ V1 → V2

v1: модель ставила 7–8 почти всем. Исправление: якоря шкалы, убрали освещённость, % в детерминированный код.

36 686 эмбеддингов — поиск за 20мс.

```
# Источник SQLite 37 763 объявлений ↓ indexer.py (батчи по 500) ↓
text-embedding-3-small # Чанк = 1 объявление "2-комн, Бостандыкский,
65м², 4/9 эт, 42 000 000т, цена м²: 646 154т" # Поиск при запросе
query = "2-комн Бостандыкский 65м²" results = chroma.query(top_k=5)
```

РЕШЕНИЕ	ВЫБОР	ПОЧЕМУ
Chunking	1 объявл = 1 чанк	Атомарная единица
Embeddings	text-emb-3-small	В 5× дешевле large
Vector DB	ChromaDB	Локально, нет latency
Retrieval	top-5 cosine	Достаточно для сравнения
Reranker	нет	Для 5 результатов overhead не оправдан

БАГ, КОТОРЫЙ НАШЛИ

RAG-объявления имели url="" → дедупликация схлопывала все 5 в 1. Исправление: ключ дедупа = title, если url пустой.

3 инструмента — подключается к любому MCP-клиенту.

TOOL 01

search_listings

```
district: "Бостандыкский" rooms: 2 price_max:
60_000_000 → [{title, price, url}]
```

Поиск объявлений по параметрам через Krisha API

TOOL 02

get_price_statistics

```
district: "Медеуский" rooms: 3 → {avg_m2:
920_000, median: 900_000, trend_4w: +0.3%}
```

Статистика рынка из Krisha Analytics

TOOL 03

estimate_fair_value

```
area_sqm: 65.0 floor: 5, floors_total: 12
condition: "хороший" → {fair_min: 45M,
fair_max: 53M}
```

Оценка справедливой стоимости

Почему MCP, а не REST API: FastMCP автоматически генерирует JSON-схему — LLM понимает инструменты без дополнительного кода. Подключается к Claude Desktop, Cursor и любому MCP-клиенту без изменений.

Golden Dataset — 30 примеров, 3 метрики.

ВЫГОДНО	ДОРОГО	РЫНОЧНАЯ
11	13	6

EDGE CASES

Здание 1940 года (–35%) · первый этаж + хороший ремонт · панель с евроремонтом · 1955 в дорогом Медеуском

ЗАПУСК

```
python3 evals/run_evals.py \ --dataset golden_dataset.json \ --config B --output results.json
```

МЕТРИКА	ЧТО ИЗМЕРЯЕТ	ОГРАНИЧЕНИЕ
Verdict Accuracy	Доля правильных вердиктов	Не показывает качество объяснения
Relevance Score	Покрытие ключевых факторов	Keyword matching — не смысл
LLM-as-Judge	GPT-4o-mini оценивает 1–5	Нет реальных пользовательских оценок

✅ eval_001 | выгодно | rel=0.50 | judge=5/5

✅ eval_002 | дорого | rel=1.00 | judge=5/5

❌ eval_003 | дорого | rel=0.60 | judge=5/5

Оправдывает ли GPT-4o 10x рост стоимости?

ГИПОТЕЗА

GPT-4o для рекомендации даёт значительно лучший LLM-judge score и оправдывает 10x рост стоимости.

МЕТРИКА	CONFIG A • GPT-4O-MINI	CONFIG B • GPT-4O
Verdict Accuracy	86.7%	86.7%
Relevance Score	0.851 ↑	0.794
LLM Judge	4.97/5 ↑	4.90/5
Стоимость/запрос	~\$0.01	~\$0.10

ВЫВОД: ГИПОТЕЗА НЕ ПОДТВЕРДИЛАСЬ

Ассурасу одинакова — вердикт детерминирован алгоритмом, не моделью. Mini не хуже gpt-4o при цене в 10x меньше.

РЕШЕНИЕ

GPT-4o **остаётся для Vision** — замены нет. Рекомендации переходят на **gpt-4o-mini** — экономия 5–10x.

4 ОШИБОЧНЫХ ВЕРДИКТА

Все 4 — граничные "рыночная цена", одинаковые в обоих конфигах. Ошибка алгоритма, не модели.

100 трейсов — каждая нода видна.

```
# config.py — 3 строки os.environ["LANGCHAIN_TRACING_V2"] = "true"
os.environ["LANGCHAIN_PROJECT"] = "krisha-agent"
os.environ["LANGCHAIN_API_KEY"] = key # Всё. LangGraph логирует
каждую ноду автоматически.
```

ВСЕГО ТРЕЙСОВ

100

ПОЛНЫХ ЗАПУСКОВ

12

НОД В КАЖДОМ

6

ЧТО ВИДНО В ДАШБОРДЕ

- Дерево нод — inputs и outputs каждой
- Latency: analyze_photos ~8c (Vision), evaluate_price ~0.1c (SQLite)
- Токены и стоимость каждого LLM-вызова
- История всех запросов с фильтрацией

КАК ОТКРЫТЬ

smith.langchain.com → Projects → krisha-agent → Last 30 days

Гипотезы, которые не подтвердились.

01 • LIVE KRISHA API

Гипотеза

API будет возвращать живые объявления для поиска похожих.

Реальность

Krisha блокирует автозапросы.

Решение

Локальный RAG на 36k объявлений из заранее собранной базы.

02 • GPT-4O VS MINI

Гипотеза

GPT-4o значительно лучше для текстовых рекомендаций.

Реальность

A/B тест опроверг: ассурасу одинакова, relevance у mini выше.

Решение

Mini для текста, gpt-4o только для Vision.

03 • VISION & ОСВЕЩЁННОСТЬ

Гипотеза

Освещённость — важный критерий оценки состояния.

Реальность

Модель путала тёмные фото с плохим ремонтом.

Решение

Убрали освещённость, добавили low_confidence флаг.

Что сделано и что дальше.

РЕАЛИЗОВАНО

LANGGRAPH 6 НОД

MCP 3 TOOLS

SKILL.MD

RAG 36K

GPT-4O VISION

HUMAN-IN-LOOP

SQLITE 37K

LANGSMITH 100 ТРЕЙСОВ

GOLDEN DATASET 30

A/B ТЕСТ

EVALS.MD

GITHUB

СЛЕДУЮЩИЙ ШАГ

- 01 Telegram бот вместо Streamlit — удобнее для мобильных
- 02 Автообновление базы раз в неделю — актуальные цены
- 03 Расширить на другие города Казахстана

86.7%

ТОЧНОСТЬ ВЕРДИКТОВ

4.97 / 5

LLM JUDGE SCORE

РЕПОЗИТОРИЙ

github.com/amirluv/krisha-agent